

UNIVERSIDADE DE SÃO PAULO

Curso de Atualização - Data Analytics para Tomada de Decisão

DetectEdu

**Análise integrada de indicadores acadêmicos para apoio à
priorização do acompanhamento pedagógico**

Projeto Aplicado Orientado à Decisão

Maria Silveira Rodrigues

2026

Resumo executivo

O DetectEdu é um MVP de apoio à decisão pedagógica desenvolvido para organizar, integrar e apresentar indicadores acadêmicos que normalmente são observados de forma separada. O sistema reúne frequência, notas, atividades atrasadas, participação, exercícios e evolução do desempenho, oferecendo uma visão consolidada da turma e uma análise individual dos estudantes.

O problema orientador é a dificuldade de priorizar, de forma consistente e transparente, quais alunos devem receber acompanhamento pedagógico mais próximo. A solução não realiza diagnóstico de aprendizagem e não substitui a avaliação profissional do professor; ela organiza sinais de atenção e apresenta os fatores que contribuíram para a priorização.

A versão final analisada utiliza Python, Streamlit, SQLite, Pandas e Plotly. A base de demonstração é inteiramente simulada e determinística, com 3 turmas, 74 alunos e 196 registros de acompanhamento. Os alunos possuem entre 1 e 4 registros, de modo a representar tanto acompanhamento regular quanto lacunas de registro.

Na leitura mais recente dos 74 alunos, 36 (48,6%) foram classificados em acompanhamento regular, 24 (32,4%) apresentaram sinais de atenção e 14 (18,9%) ficaram em prioridade de acompanhamento. Os testes também mostraram que alunos com notas semelhantes podem receber prioridades diferentes quando frequência, participação, atrasos e exercícios são analisados em conjunto, além de evidenciar sensibilidade nos casos próximos aos limites de pontuação.

Os resultados indicam que o principal valor do DetectEdu está na consolidação dos dados e na explicitação dos motivos da sinalização. A classificação deve ser entendida como apoio à priorização e à observação, especialmente porque as faixas utilizadas são heurísticas e ainda não possuem validação pedagógica externa.

Pergunta central

Como a análise integrada de indicadores acadêmicos pode apoiar professores na priorização de alunos para acompanhamento pedagógico?

Decisão apoiada

Quais alunos devem ser priorizados para acompanhamento pedagógico e quais indicadores justificam essa prioridade?

1. Contexto e problema

1.1 Contexto

O projeto está situado no contexto educacional, especialmente em situações nas quais um professor acompanha uma turma ao longo de um semestre e registra informações acadêmicas em momentos diferentes. Presença, notas, atividades, participação e exercícios são fontes relevantes de informação, mas podem permanecer distribuídas entre sistemas, planilhas, anotações e percepções individuais.

Neste trabalho, o cenário é simulado e representa turmas do ensino médio acompanhadas por uma professora de Matemática. A simulação permite testar o comportamento do MVP sem utilizar informações pessoais reais e possibilita repetir os mesmos cenários em diferentes execuções. Neste projeto, a autora atua como responsável pela concepção, desenvolvimento e análise do protótipo, aplicando os conhecimentos do curso para estruturar uma solução orientada à tomada de decisão.

1.2 Problema central

Quando os registros são consultados separadamente, a percepção de mudanças pode ocorrer apenas depois que um problema já se tornou evidente. Além disso, alunos com notas semelhantes podem apresentar contextos diferentes em frequência, participação, atrasos e realização de exercícios. O problema, portanto, não é apenas ter dados disponíveis, mas integrá-los de forma que apoiem uma decisão recorrente: quem precisa ser observado primeiro e por quê.

1.3 Relevância para a tomada de decisão

A priorização de acompanhamento é limitada por tempo e atenção. Um professor acompanha toda a turma, mas não consegue dedicar o mesmo nível de acompanhamento individual a todos simultaneamente. Um painel integrado pode reduzir o esforço de comparação manual, tornar os critérios mais explícitos e destacar casos que merecem observação mais próxima.

1.4 Objetivos

Objetivo geral: desenvolver e analisar um MVP que integre indicadores acadêmicos e apoie a priorização de alunos para acompanhamento pedagógico.

- Estruturar o registro periódico de turmas, alunos e acompanhamentos.
- Padronizar indicadores registrados em escalas diferentes.
- Apresentar visão consolidada da turma e análise individual com histórico.
- Documentar e testar uma regra heurística de priorização.
- Comparar perfis de alunos e avaliar a sensibilidade das faixas de classificação.
- Identificar limitações, riscos de interpretação e condições para uso responsável.

1.5 Delimitação do escopo

Quadro 1 - Delimitação do escopo

O projeto contempla	O projeto não contempla
Dados simulados e fictícios	Diagnóstico clínico, psicológico ou pedagógico
Análise descritiva e dashboard	Modelo de Machine Learning nesta etapa
Regra heurística de priorização	Validação científica das faixas utilizadas
Histórico de acompanhamento	Uso institucional em produção
Apoio à priorização do professor	Substituição da avaliação profissional

2. Ferramenta e método aplicado

2.1 Abordagem escolhida

A abordagem combina estruturação de dados, análise descritiva, visualização em dashboard e uma regra heurística de priorização. A escolha é compatível com o problema porque os dados necessários já fazem parte do acompanhamento cotidiano do professor; o ganho esperado está em consolidá-los, compará-los e explicar os sinais observados.

O dashboard não produz uma resposta automática e definitiva. A saída é apresentada em três níveis descritivos e acompanhada dos indicadores que contribuíram para a pontuação. Dessa forma, o professor mantém a responsabilidade pela interpretação e pode considerar informações contextuais que não estão representadas no sistema.

2.2 Tecnologias utilizadas

Tabela 1 - Tecnologias utilizadas no MVP

Tecnologia	Uso no projeto
Python	Implementação da lógica e integração dos componentes.
Streamlit	Interface web, navegação, formulários e dashboard.
SQLite	Persistência local de turmas, alunos e acompanhamentos.
Pandas	Organização, transformação e consolidação dos dados.
Plotly	Visualização dos indicadores e da evolução.

2.3 Indicadores acadêmicos

Tabela 2 - Indicadores utilizados

Indicador	Cálculo/registro	Leitura pretendida
Frequência	(aulas dadas - faltas) / aulas dadas	Regularidade da presença.
Nota de provas	Nota obtida / nota máxima, em escala 0-10	Desempenho em avaliações.
Nota de atividades	Nota obtida / nota máxima, em escala 0-10	Desempenho contínuo.
Atividades atrasadas	Quantidade registrada no período	Regularidade no cumprimento de prazos.
Participação	Escala 0-10 informada pelo professor	Envolvimento observado em aula.
Taxa de exercícios	Resolvidos / propostos	Realização das práticas propostas.
Evolução	Diferença entre a média atual e a anterior	Tendência de melhora, sem variação relevante ou queda.

O campo “atividades entregues” é mantido como informação de contexto, mas não influencia a pontuação. Quando nenhum exercício foi proposto no período, a taxa de exercícios é tratada como “não aplicável” e não adiciona pontos ao aluno.

2.4 Regra heurística final do MVP

Tabela 3 - Pontuação por indicador

Indicador	0 pontos	1 ponto	2 pontos
Frequência	≥ 85%	75% a 84,9%	< 75%
Nota de provas	≥ 7,0	6,0 a 6,9	< 6,0
Nota de atividades	≥ 7,0	6,0 a 6,9	< 6,0
Atividades atrasadas	0 a 1	2 a 3	4 ou mais
Participação	≥ 7,0	5,0 a 6,9	< 5,0
Taxa de exercícios	≥ 80% ou N/A	60% a 79,9%	< 60%
Evolução	melhora / sem variação / sem histórico	-	queda significativa

Tabela 4 - Classificação da pontuação total

Pontuação total	Categoria	Interpretação
0 a 3	Acompanhamento regular	Não há combinação forte de sinais na regra atual.
4 a 7	Sinais de atenção	Há indicadores que justificam observação mais próxima.
8 ou mais	Prioridade de acompanhamento	O conjunto de sinais recomenda priorização na leitura do professor.

Observação metodológica

As faixas acima são hipóteses operacionais do MVP e não critérios pedagógicos validados. Elas foram testadas quanto ao funcionamento e à sensibilidade, mas precisam de validação com profissionais da educação antes de qualquer uso real.

3. Execução prática

3.1 Desenvolvimento e fluxo do MVP

O protótipo foi organizado em módulos de interface, persistência, formulários, análise, regras de negócio e gráficos. A aplicação permite cadastrar turmas e alunos, registrar acompanhamentos periódicos, consultar indicadores consolidados por turma e visualizar a situação individual de cada estudante.

1. Cadastro da turma e de seus alunos.
2. Registro periódico de frequência, notas, atividades, participação e exercícios.
3. Padronização dos indicadores e aplicação da regra heurística.
4. Visualização da turma por meio de métricas, gráficos e tabela de alunos.
5. Consulta individual com fatores de atenção, sugestões gerais e evolução temporal.

Repositório do projeto: github.com/mayasrl/DetectEdu

3.2 Base simulada definitiva

A base final foi criada de forma determinística, sem geração aleatória em cada execução. Isso permite repetir os mesmos resultados, comparar alterações do código e utilizar as mesmas evidências no relatório. Os nomes, matrículas e registros são fictícios.

Tabela 5 - Estrutura da base simulada

Elemento	Quantidade / característica
Turmas	3
Alunos	74
Registros de acompanhamento	196
Alunos com 1 registro	8
Alunos com 2 registros	20
Alunos com 3 registros	36
Alunos com 4 registros	10
Períodos possíveis	10/03, 10/04, 10/05 e 10/06 de 2026

Os perfis simulados incluem desempenho consistente, melhora, queda, baixa frequência, notas baixas, baixa participação, atrasos, combinação de sinais moderados, situações críticas, casos contraditórios e valores próximos aos limites de classificação. Também foram incluídos registros em que exercícios não se aplicam e lacunas temporais de acompanhamento.

3.3 Testes e correções realizadas

Quadro 2 - Principais blocos de teste

Bloco	Cenários avaliados	Resultado final
Banco e execução	Inicialização, seed, integridade e exclusões em cascata	Aprovado
Turmas e alunos	Criação, edição, exclusão e matrícula duplicada	Aprovado
Acompanhamentos	Criação, edição, exclusão, duplicidade por data e limites	Aprovado
Cálculos	Frequência, notas, exercícios, evolução, pontuação e fronteiras	Aprovado
Dashboard	Turma vazia, aluno sem registro, gráficos e análise individual	Aprovado
Sensibilidade	Alteração de um indicador por vez e reclassificação	Concluído

Quadro 3 - Correções relevantes identificadas durante os testes

Problema identificado	Ajuste realizado
Alguns gráficos quebravam por configuração duplicada dos eixos	Configuração dos eixos foi separada do layout global do Plotly.
Turma sem alunos podia gerar erro de coluna inexistente	Foi incluído tratamento para DataFrame vazio.
Tags </div> apareciam nos cards do Streamlit	A renderização dos cards foi ajustada para o componente HTML adequado.
Zero exercícios propostos era interpretado como taxa 0%	O indicador passou a ser “não aplicável” e não penaliza o aluno.
Estabilidade das notas adicionava 1 ponto	“Sem variação relevante” passou a ter 0 ponto; apenas queda adiciona 2.
Aluno sem acompanhamento não possuía todas as colunas esperadas	A estrutura do registro vazio foi harmonizada com a tabela do dashboard.

4. Resultados e análise crítica

4.1 Distribuição geral das classificações

A leitura do registro mais recente de cada aluno resultou em 36 estudantes (48,6%) em acompanhamento regular, 24 (32,4%) com sinais de atenção e 14 (18,9%) em prioridade de acompanhamento.

Tabela 6 - Distribuição das categorias por turma

Turma	Alunos	Regular	Sinais de atenção	Prioridade
1º Ano A - Manhã	25	13 (52,0%)	8 (32,0%)	4 (16,0%)
1º Ano B - Manhã	30	12 (40,0%)	11 (36,7%)	7 (23,3%)
2º Ano A - Tarde	19	11 (57,9%)	5 (26,3%)	3 (15,8%)
Total	74	36 (48,6%)	24 (32,4%)	14 (18,9%)

O 1º Ano B apresenta a maior concentração de alunos nas duas categorias de atenção: 18 de 30 estudantes (60,0%). Esse resultado não significa que a turma possua um “problema” diagnosticado; ele indica que, segundo os critérios do MVP, é a turma em que o professor encontraria maior quantidade de casos para revisar com prioridade.

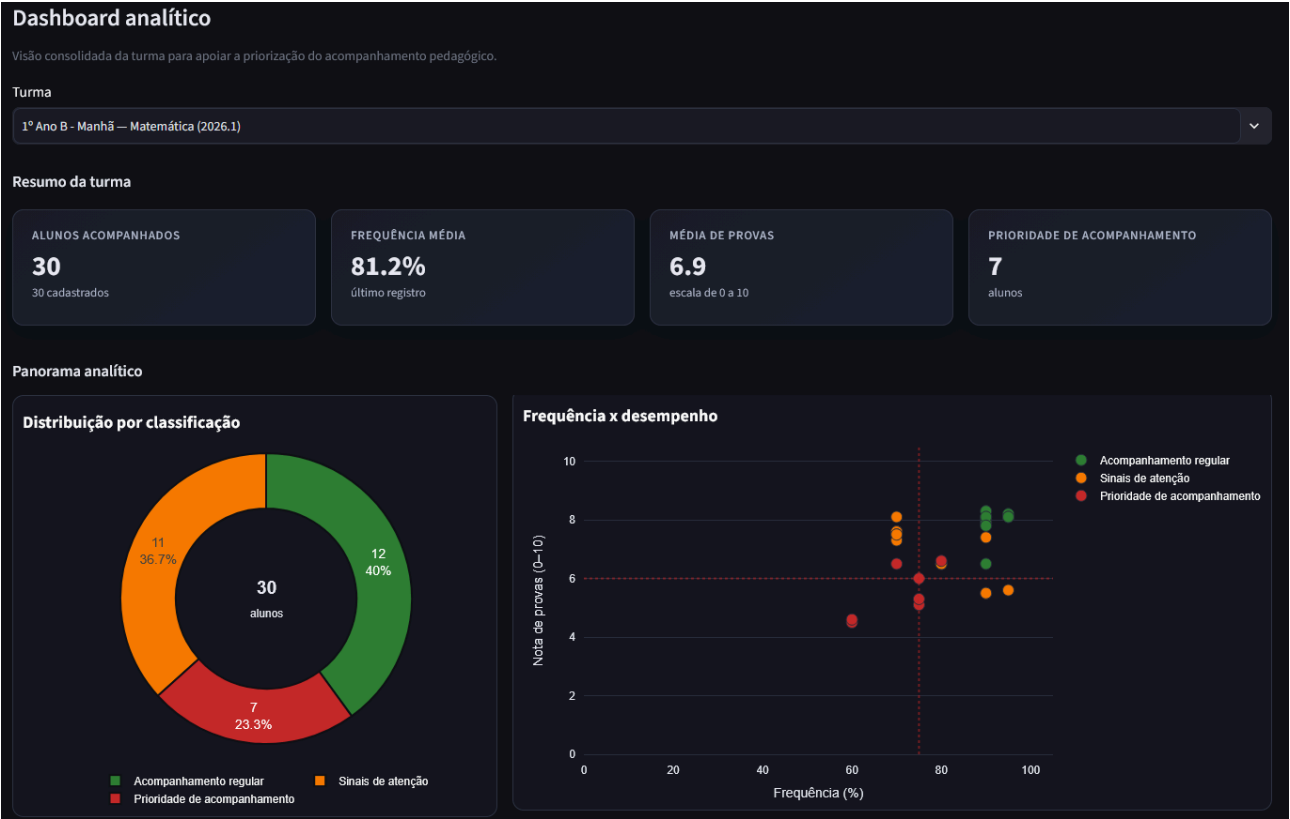


Figura 1 - Visão geral do dashboard analítico do 1º Ano B. Fonte: elaboração própria a partir do MVP DetectEdu (2026).

4.2 Relação entre os indicadores

As médias por classificação apresentam uma progressão coerente: os grupos com maior prioridade possuem, em média, menor frequência, menores notas, menor participação, menor taxa de exercícios e mais atividades atrasadas. Esse comportamento não valida as faixas utilizadas, mas indica que a regra está organizando os perfis simulados de forma consistente com os sinais que foram definidos no MVP.

Tabela 7 - Médias dos indicadores por classificação

Indicador	Regular	Sinais de atenção	Prioridade
Frequência	90,0%	79,6%	70,4%
Nota de provas	7,66	7,01	5,46
Nota de atividades	7,78	7,03	5,49
Atividades atrasadas	0,50	2,00	3,64
Participação	7,73	5,92	4,64
Taxa de exercícios*	79,3%	64,0%	56,6%
Pontuação média	1,25	5,46	10,71

* A média da taxa de exercícios desconsidera registros em que nenhum exercício foi proposto.

Tabela 8 - Fatores de atenção mais frequentes no último registro

Fator	Alunos sinalizados
Atividades atrasadas	39
Taxa de exercícios	37
Frequência	33
Nota de atividades	32
Participação em aula	32
Nota de provas	31
Queda na evolução	9



Figura 2 - Indicadores médios da turma e notas de provas por aluno no 1º Ano B. Fonte: elaboração própria a partir do MVP DetectEdu (2026).

A Figura 2 reforça que a cor da classificação não é uma simples tradução da nota de prova. Há alunos com notas altas em “Sinais de atenção” e estudantes com notas semelhantes em categorias distintas, porque a pontuação considera outros indicadores simultaneamente.

4.3 Caso comparativo: mesmas notas, prioridades diferentes

O contraste entre Júlia Martins e Fernanda Lacerda é o exemplo mais direto do valor da análise integrada. As duas possuem média de notas igual a 8,35 no registro mais recente, mas os demais indicadores são bastante diferentes.

Tabela 9 - Comparação entre Júlia Martins e Fernanda Lacerda

Indicador	Júlia Martins	Fernanda Lacerda
Frequência	90,0%	70,0%
Nota de provas	8,10	8,20
Nota de atividades	8,60	8,50
Média das notas	8,35	8,35
Atividades atrasadas	0	2
Participação	8,4 / 10	4,4 / 10
Taxa de exercícios	88,0%	48,0%
Pontuação	0	7
Classificação	Acompanhamento regular	Sinais de atenção

Se apenas as notas fossem consideradas, as duas estudantes pareceriam equivalentes. No entanto, Fernanda apresenta frequência menor, menor participação, atividades atrasadas e taxa de exercícios reduzida. O painel torna essas diferenças visíveis e oferece uma justificativa objetiva para que o professor observe o caso com mais atenção, sem afirmar a causa desses sinais.

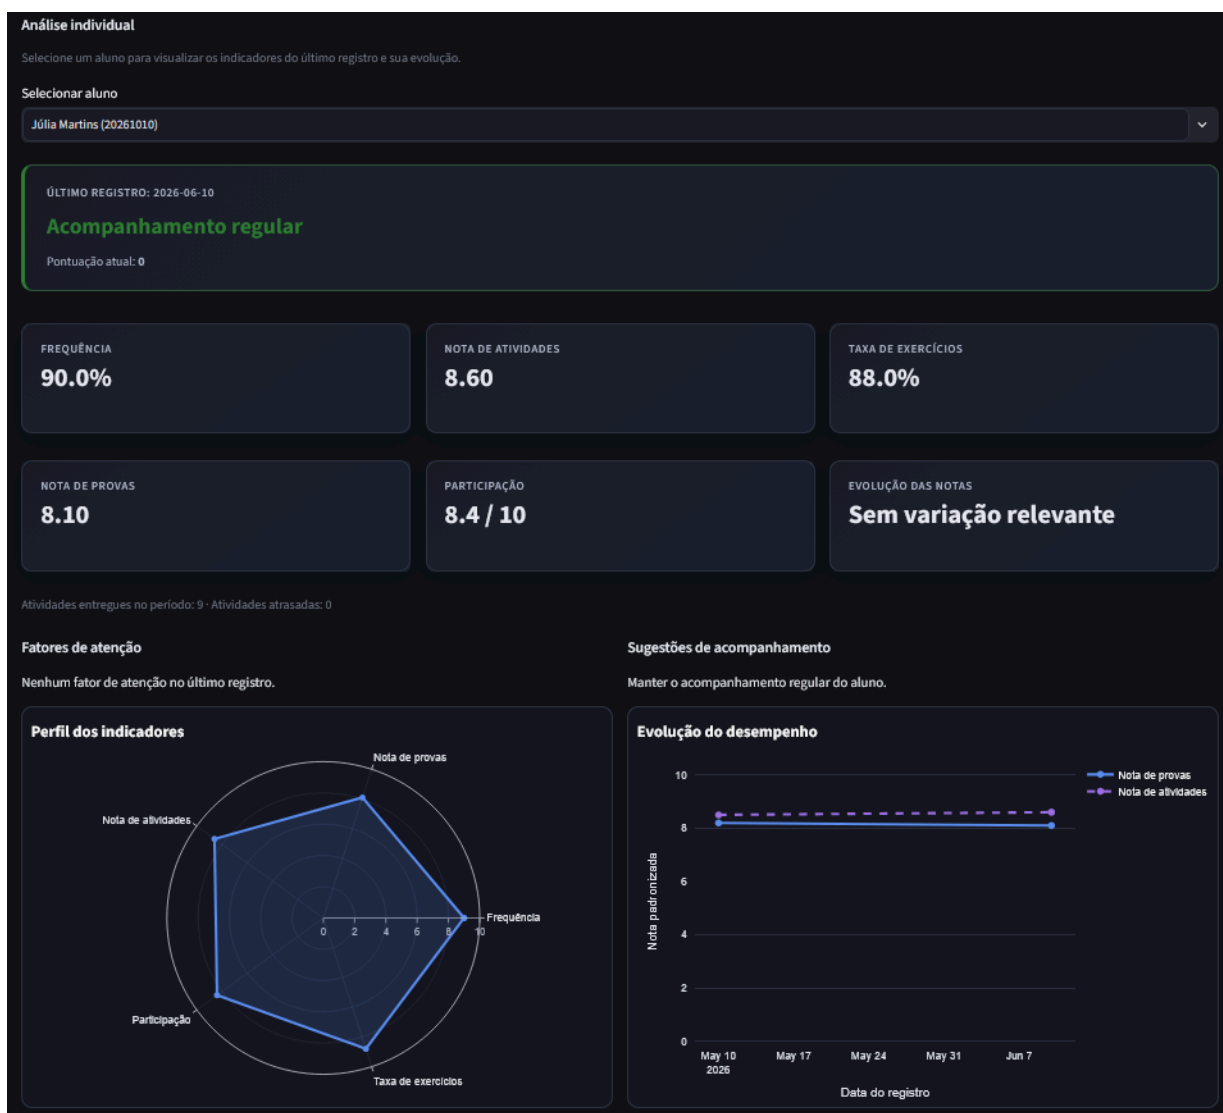


Figura 3 - Análise individual de Júlia Martins: acompanhamento regular e ausência de fatores de atenção no último registro. Fonte: elaboração própria (2026).

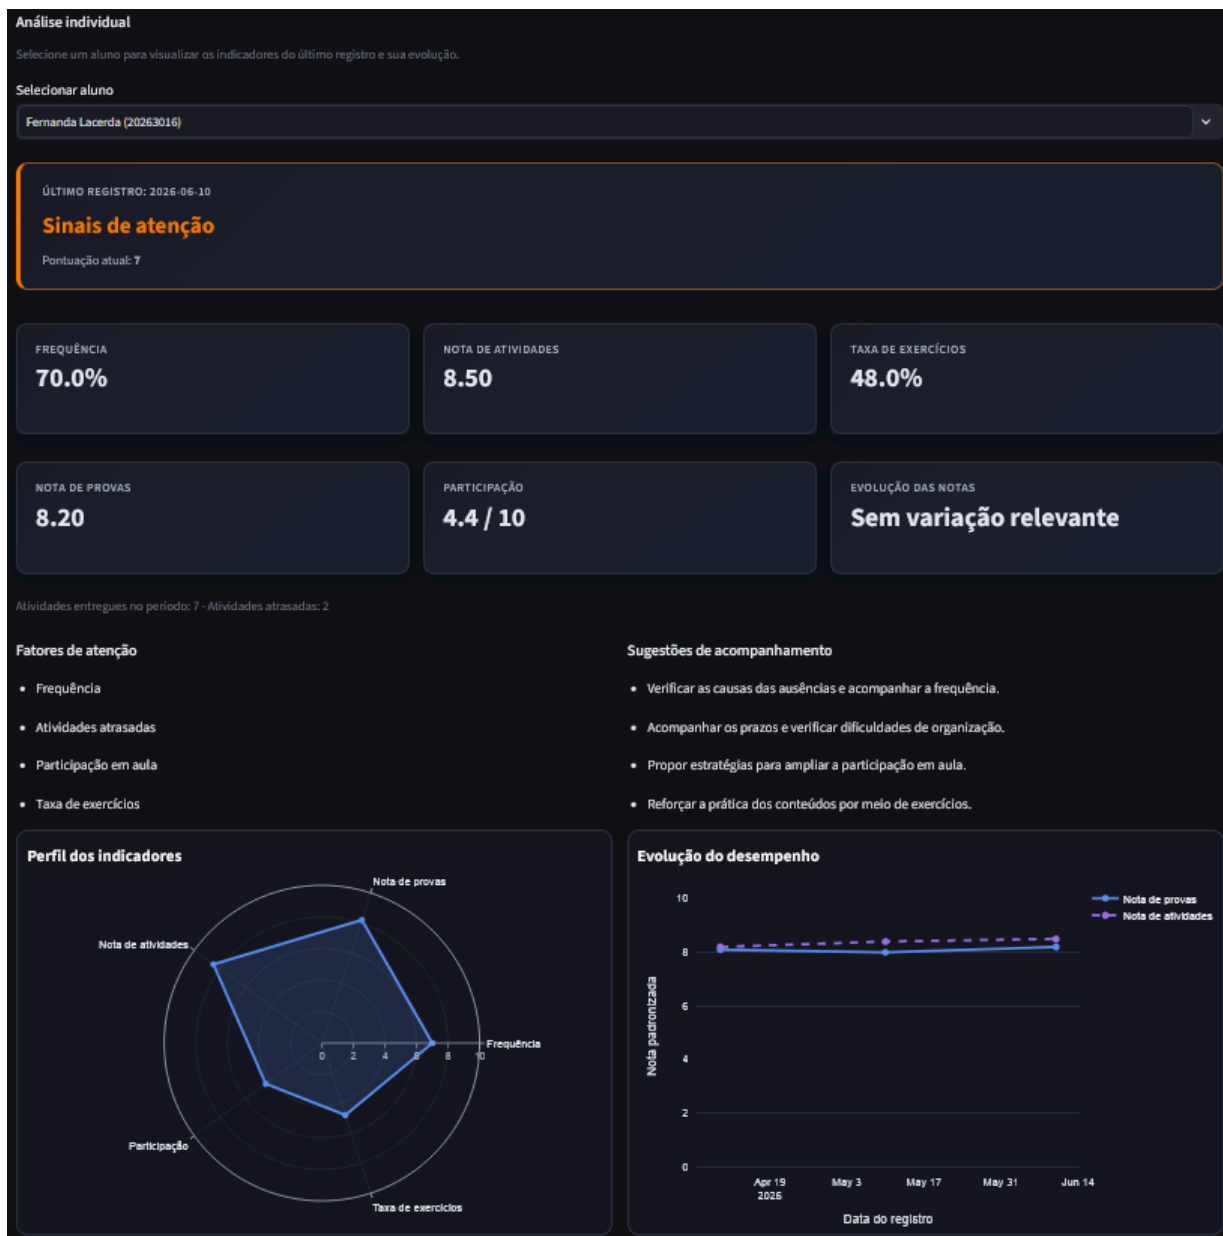


Figura 4 - Análise individual de Fernanda Lacerda: boas notas combinadas a sinais de atenção em frequência, atrasos, participação e exercícios. Fonte: elaboração própria (2026).

Leitura para a decisão

O caso comparativo mostra que a análise integrada muda a pergunta de “quem tem nota baixa?” para “quais combinações de sinais justificam acompanhamento mais próximo?”. Essa mudança amplia a informação disponível para a decisão sem retirar do professor o julgamento contextual.

4.4 Perfis com mesma média e níveis diferentes de prioridade

Outro contraste ocorre entre Rafael Mendes e Otávio Coelho. Ambos possuem média de notas 6,5, porém Rafael apresenta 90% de frequência, nenhum atraso, participação 7,0 e taxa de exercícios 80%, totalizando 2 pontos e acompanhamento regular. Otávio apresenta 70% de frequência, 4 atividades atrasadas, participação 6,0 e taxa de exercícios 50%, totalizando 9 pontos e prioridade de acompanhamento.

Tabela 10 - Rafael Mendes x Otávio Coelho

Indicador	Rafael Mendes	Otávio Coelho
Média das notas	6,5	6,5
Frequência	90,0%	70,0%
Atividades atrasadas	0	4
Participação	7,0	6,0
Taxa de exercícios	80,0%	50,0%
Pontuação	2	9
Classificação	Acompanhamento regular	Prioridade de acompanhamento

Esse segundo exemplo reduz a possibilidade de interpretar o resultado Júlia-Fernanda como um caso isolado. Novamente, a mesma média acadêmica está associada a necessidades de acompanhamento diferentes quando outros indicadores são considerados.

4.5 Valor do histórico de acompanhamento

O histórico permite distinguir uma fotografia do momento de uma tendência. Camila Nunes apresenta trajetória de melhora, enquanto Eloá Macedo apresenta queda progressiva. O último registro, portanto, pode ser interpretado à luz da direção em que o desempenho está se movendo.

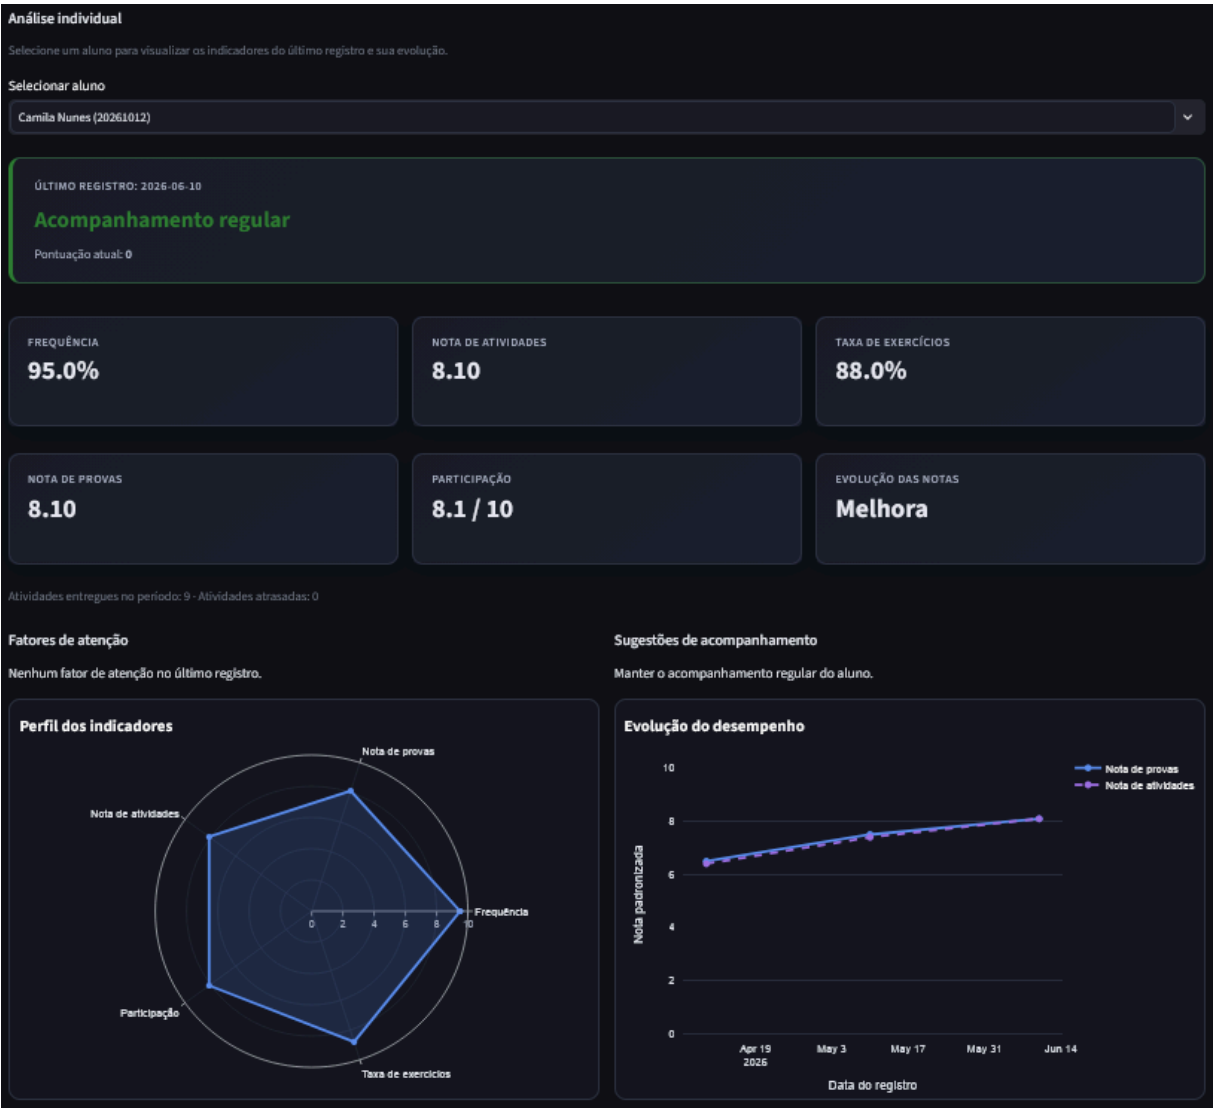


Figura 5 - Camila Nunes: trajetória de melhora e classificação atual em acompanhamento regular. Fonte: elaboração própria (2026).

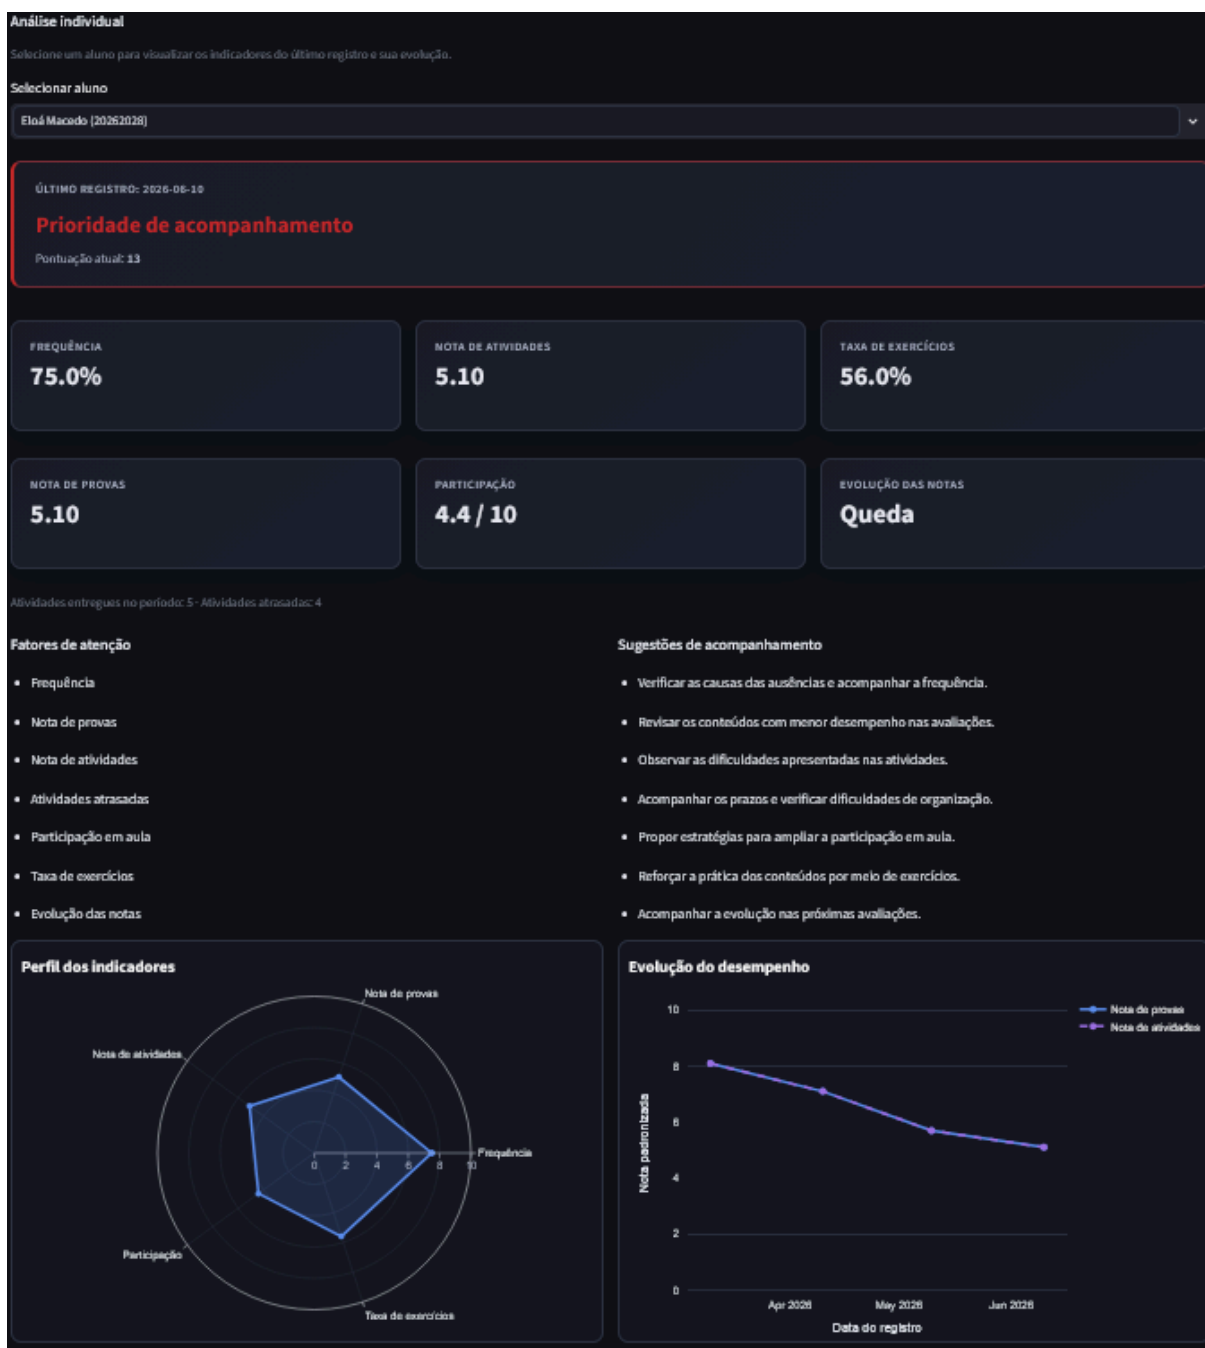


Figura 6 - Eloá Macedo: trajetória de queda e classificação atual em prioridade de acompanhamento. Fonte: elaboração própria (2026).

Na base final, 50 alunos apresentaram “sem variação relevante”, 7 apresentaram melhora, 9 apresentaram queda e 8 não possuíam histórico suficiente para comparação. Entre os 9 casos de queda, a remoção apenas dos 2 pontos referentes à evolução alteraria a categoria de 2 alunos; nos demais, os outros indicadores já eram suficientes para manter a classificação. Isso sugere que a evolução influencia a leitura sem se tornar, na maior parte dos casos, o único fator determinante.

4.6 Teste de sensibilidade

O teste de sensibilidade foi realizado alterando um indicador por vez no último registro e mantendo os demais componentes da pontuação constantes. O objetivo foi verificar o quanto pequenas mudanças poderiam deslocar alunos entre as faixas 0-3, 4-7 e 8 ou mais.

Tabela 11 - Sensibilidade a pequenas alterações em um indicador

Cenário	Alunos que mudaram de categoria
Frequência -5 p.p.	0
Nota de provas -0,5	2
Nota de atividades -0,5	2
+1 atividade atrasada	0
Participação -0,5	5
Taxa de exercícios -10 p.p.	5
Frequência +5 p.p.	6
Nota de provas +0,5	4
Nota de atividades +0,5	4
-1 atividade atrasada	4
Participação +0,5	0
Taxa de exercícios +10 p.p.	6

A sensibilidade se concentra nos alunos próximos aos limites. A base final possui 5 alunos com 3 pontos, 6 com 4 pontos, 5 com 7 pontos e 2 com 8 pontos, totalizando 18 alunos (24,3%) diretamente nas pontuações de fronteira entre as categorias.

Exemplo de fronteira - Davi Peixoto

Davi possui 4 pontos e está em “Sinais de atenção”. Se sua frequência passar de 70% para 75%, a pontuação de frequência cai de 2 para 1 e o total passa de 4 para 3, alterando a categoria para “Acompanhamento regular”. O caso mostra que a categoria deve ser lida junto da pontuação e dos indicadores, principalmente nas fronteiras.

4.7 Análise crítica e limitações

- A regra simples de soma facilita a explicação, mas atribui o mesmo peso máximo a indicadores de naturezas diferentes. Isso não significa que frequência, nota, participação e evolução tenham a mesma relevância pedagógica em todos os contextos.
- A participação é subjetiva e depende da consistência do registro docente. Professores diferentes podem utilizar a escala 0-10 de maneiras distintas.
- Os limites de frequência, notas, participação, exercícios e pontuação total foram definidos para o MVP e não foram validados cientificamente ou com uma equipe pedagógica.
- Casos próximos às fronteiras são sensíveis a pequenas alterações. Por isso, a classificação não deve ser interpretada como rótulo fixo nem como decisão automática.
- Dados faltantes ou não aplicáveis precisam ser distinguidos de desempenho baixo. O caso de exercícios não propostos mostrou que tratar ausência como zero produziria penalização indevida.
- A base é simulada e foi criada propositalmente para conter perfis variados. Os resultados demonstram o comportamento da ferramenta nesses cenários, mas não permitem afirmar desempenho em uma população real.

Diante dessas limitações, a interpretação mais adequada é utilizar o DetectEdu como mecanismo de triagem e organização da atenção: o painel aponta onde olhar primeiro e quais dados justificam essa leitura; a avaliação do contexto e a decisão final continuam sendo do professor.

5. Reflexão e próximos passos

5.1 Como a análise muda a decisão

Antes da consolidação, uma decisão de acompanhamento pode se apoiar em um único dado mais visível, como uma nota baixa, ou exigir a comparação manual de diferentes registros. O DetectEdu transforma essa abordagem ao reunir os indicadores, explicitar a pontuação, apresentar fatores de atenção e manter a evolução temporal em um mesmo fluxo de consulta.

Os casos comparativos mostram a consequência prática dessa mudança. Júlia e Fernanda têm a mesma média de notas, mas a análise integrada diferencia suas situações. Rafael e Otávio também possuem a mesma média, porém aparecem em níveis de prioridade distintos. Assim, o painel não apenas resume dados: ele altera a forma de formular a decisão, deslocando o foco de um indicador isolado para a combinação de evidências disponíveis.

5.2 Aprendizados do projeto

- Transparência da regra é mais importante do que apresentar apenas uma categoria final.
- Histórico é necessário para distinguir estabilidade, recuperação e deterioração.
- Tratamento de dados não aplicáveis influencia diretamente a justiça da pontuação.
- Testes de sensibilidade são necessários para identificar classificações frágeis próximas aos limites.
- Uma ferramenta de apoio deve evidenciar limitações e manter espaço para revisão humana.

5.3 Próximos passos recomendados

- Submeter indicadores, faixas e linguagem à avaliação de professores e profissionais da educação.
- Testar o dashboard com usuários para verificar clareza, esforço de registro e utilidade na rotina.
- Definir políticas para dados ausentes, mudanças de professor e diferenças entre disciplinas.
- Somente após validação, avaliar a aplicação com dados reais devidamente autorizados e anonimizados.
- Revisar pesos ou modelos mais sofisticados apenas se houver evidência de que a regra simples é insuficiente para a decisão.

5.4 Ética, privacidade e uso responsável

O estudo utiliza exclusivamente dados simulados. Nomes, matrículas e acompanhamentos foram criados para demonstração e não correspondem a estudantes reais. Essa escolha evita exposição de dados pessoais durante o desenvolvimento e a produção das evidências.

Em eventual aplicação futura com dados reais, seria necessário definir base legal, controles de acesso, minimização de dados e procedimentos de anonimização em conformidade com a LGPD. A categoria não deve ser utilizada como rótulo permanente do aluno nem compartilhada fora do contexto pedagógico sem justificativa adequada.

Também é necessário reconhecer que os indicadores observados são parciais: frequência, nota, atrasos e participação podem refletir fatores pessoais, sociais ou institucionais que o sistema não conhece. Por isso, a sinalização deve iniciar uma análise contextual, e não encerrá-la.

5.5 Declaração de uso de IA generativa

Este trabalho utilizou o ChatGPT (OpenAI) como apoio à revisão do código e dos textos do projeto (uso moderado) e à geração da base fictícia de dados utilizada para testes e demonstração do protótipo do MVP (uso substancial nessa etapa). A base simulada foi empregada exclusivamente para fins de demonstração, testes e análise do funcionamento da ferramenta e não corresponde a estudantes reais.

As regras de classificação, os ajustes metodológicos, a validação dos resultados e a interpretação apresentada neste trabalho foram revisados pela autora ao longo do desenvolvimento do projeto.

5.6 Conclusão

O Projeto Aplicado demonstrou que a integração de indicadores acadêmicos pode apoiar a priorização de alunos ao tornar visíveis combinações de sinais que não aparecem quando as informações são consultadas isoladamente. Na base simulada, alunos com a mesma média de notas foram classificados de forma distinta devido a diferenças de frequência, participação, atrasos, exercícios e trajetória, evidenciando o ganho de uma leitura multidimensional.

Ao mesmo tempo, os testes de sensibilidade mostraram que as faixas possuem limitações e que pequenas alterações podem mudar a categoria de alunos próximos às fronteiras. Portanto, o resultado mais relevante não é a criação de um rótulo, mas a organização de uma leitura transparente, explicável e revisável. O DetectEdu se mostra adequado como MVP de apoio à decisão, desde que sua saída permaneça subordinada ao julgamento docente e que futuras aplicações sejam precedidas de validação pedagógica e cuidados com privacidade.

Referências e materiais

UNIVERSIDADE DE SÃO PAULO. Diretrizes do Projeto Aplicado Orientado à Decisão. Material do curso Data Analytics para Tomada de Decisão, 2026.

SILVEIRA RODRIGUES, Maria. DetectEdu: código-fonte do MVP. GitHub, 2026.
github.com/mayasrl/DetectEdu

Material empírico do projeto: base simulada determinística do DetectEdu, versão v6, composta por 3 turmas, 74 alunos e 196 acompanhamentos fictícios.